

GreenFinance-Scorer · Prompt 4.2 (Docling + OCR)

Donnees conservees apres traitement · microsoft

Contexte

Script : notebooks/_prompt_4_2_structuration.py
Sortie : data_test/prompt_4_2_structuration.json
Document PDF traite : storage/pilot_corpus/microsoft.pdf
Genere le : 2026-08-13 17:21 UTC

Donnees retenues (integrales)

Statut de conversion	ConversionStatus.SUCCESS
Temps de traitement	342.5 s (~5.7 min)
Pages (Docling)	25
Pages (PyMuPDF, verification independante)	25
Comptages de pages concordants	Oui
Tableaux structures detectes	28
Erreurs	Aucune

Ce qui n'est PAS conserve

Ce script de validation ne garde que les statistiques ci-dessus. L'objet DoclingDocument complet (texte extrait, contenu des tableaux, mise en page, provenance par page) est construit en memoire pendant la conversion puis rejete a la fin de chaque rapport · il n'est jamais ecrit sur disque par ce script. Le Prompt 4.3 (recherche semantique) necessitera donc une nouvelle conversion Docling, cette fois avec sauvegarde via doc.save_as_json().